

团 体 标 准

T/SZDEIA 2—2026

安全应急管理代理式人工智能建设规范

Specification for construction of safety emergency management agentic artificial intelligence

2026-9-14 发布

2026-9-30 实施

深圳市数字经济产业促进会 发 布



公布日期：2026-09-28 下载时间：2026-09-28 20:04:02

目 次

前言 II

1 范围 1

2 规范性引用文件 1

3 术语和定义 1

4 缩略语 1

5 总体架构 2

6 功能要求 3

7 性能要求 5

8 接口要求 6

9 部署环境要求 7

10 安全要求 7

11 代理式人工智能调试 9

前 言

本文件按照GB/T 1.1—2020《标准化工作导则 第1部分：标准化文件的结构和起草规则》的规定起草。

请注意本文件的某些内容可能涉及专利。本文件的发布机构不承担识别专利的责任。

本文件由深圳市益环科技有限公司提出。

本文件由深圳市数字经济产业促进会归口。

本文件起草单位：深圳市益环科技有限公司、华南理工大学、生态环境部华南环境科学研究所（生态环境部生态环境应急研究所）、南方科技大学、深圳职业技术大学、中电信数智科技（深圳）有限公司、中国联合网络通信有限公司深圳市分公司、中铁上海设计院集团有限公司、伊登软件国际有限公司、中机建设（澳门）有限公司、广东金盛泰黄金珠宝首饰有限责任公司、深圳市朗诚科技股份有限公司、深圳市伊登软件有限公司、广东盛唐（龙岗）律师事务所、深圳市益天环保科技有限公司、深圳市知水科技有限公司、深圳市金天福科技有限公司。

本文件主要起草人：陈晋灶、蔡俊、沈先杰、叶代启、胡芸、李明斌、陈思莉、李佳威、张丛光、王川、孙飞宇、冷威、戴鹏、柏锋、向鑫、李翊、曾德春、黄治、陈丽仪、刘昌伟、刘卫华、叶惠陆、王勇飞、陈淼升、潘敏、肖勇、喻建平。

安全应急管理代理式人工智能建设规范

1 范围

本文件确立了安全应急管理代理式人工智能（以下简称“代理式人工智能”）的总体架构，规定了功能、性能、接口、部署环境和安全要求。

本文件适用于电力系统、石油化工、水处理与供水系统、交通运输和制造业生产线领域安全应急管理代理式人工智能的设计、开发、部署、测试与运维。

2 规范性引用文件

下列文件中的内容通过文中的规范性引用而构成本文件必不可少的条款。其中，注日期的引用文件，仅该日期对应的版本适用于本文件；不注日期的引用文件，其最新版本（包括所有的修改单）适用于本文件。

GB/T 22239—2019 信息安全技术 网络安全等级保护基本要求
GB/T 35273 信息安全技术 个人信息安全规范
GB/T 41479 信息安全技术 网络数据处理安全要求
GB/T 41867—2022 信息技术 人工智能 术语
GB/T 43697 数据安全技术 数据分类分级规则
GB/T 44462.4—2026 工业互联网企业网络安全 第4部分：数据防护要求
GB/T 45574 数据安全技术 敏感个人信息处理安全要求

3 术语和定义

GB/T 41867—2022界定的以及下列术语和定义适用于本文件。

3.1

应急管理 emergency management

为预防、处置、恢复突发事件，统筹开展的风险防控、监测预警、应急准备、响应处置和恢复重建等全过程管理活动。

3.2

代理式人工智能 agentic artificial intelligence

具备自主感知、推理、规划、工具调用与执行能力，能独立完成多步骤复杂任务的人工智能系统。

4 缩略语

下列缩略语适用于本文件。

AI：人工智能（Artificial Intelligence）
ANP：智能体网络协议（Agent Network Protocol）
API：应用程序编程接口（Application Programming Interface）
A2A：智能体到智能体（Agent-to-Agent）
App：应用程序（Application）
BIM：建筑信息模型（Building Information Modeling）
CPU：中央处理器（Central Processing Unit）
HTML：超文本标记语言（Hyper Text Markup Language）
HTTP：超文本传输协议（Hypertext Transfer Protocol）
HTTPS：超文本传输安全协议（Hypertext Transfer Protocol Secure）
JSON：JavaScript对象表示法（JavaScript Object Notation）
K8s：容器编排系统（Kubernetes）

LLM: 大语言模型 (Large Language Model)

MCP: 模型控制协议 (Model Control Protocol)

OCAA: 对象、状况、行动、指派任务 (Object、Condition、Action、Assignment)

PPE: 个人防护装备 (Personal Protective Equipment)

RECEVOR: 救援、暴露、围堵、灭火、通风、检修、恢复 (Rescue、Exposure、Containment、Extinguishment、Ventilation、Overhaul、Recovery)

RTMP: 实时消息传输协议 (Real-Time Messaging Protocol)

RTSP: 实时流传输协议 (Real-Time Streaming Protocol)

SSE: 服务器发送事件 (Server-Sent Events)

TLS: 传输层安全协议 (Transport Layer Security)

UTF-8: 8位通用转换格式 (8-bit Unicode Transformation Format)

Web: 万维网 (World Wide Web)

XFS: 高性能日志文件系统 (X File System)

ZFS: Zettabyte 文件系统 (Zettabyte File System)

2D: 二维 (Two-Dimensional)

3D: 三维 (Three-Dimensional)

5 总体架构

5.1 基本要求

5.1.1 安全应急管理代理式人工智能应为系统级智能架构, 编排多个专业化代理, 整合大语言模型与外部工具。系统分为前端用户交互模块与后端智能推理模块, 应整合外部大语言模型群组与第三方代理式人工智能从集, 前端适配应急组织人员人机交互场景, 后端接收请求并输出应急决策建议。

5.1.2 应急管理代理式人工智能应具备主动执行、主动推送、状态化记忆、工具拓展和反思优化五大核心能力, 实现复杂应急任务自主处理。

5.1.3 大语言模型应提供自然语言交互、语意修订和文字语音双向互译能力, 快速响应数据请求。

5.1.4 代理式人工智能通信应支持 MCP、A2A、ANP 协议, 通过统一工具接口封装, 兼容不同协议工具调用。

5.2 基础设施层

5.2.1 硬件设施包含服务器、图形处理器 (GPU) 计算设备、存储设备、网络设备、环境感知终端 (传感器、AI 摄像头) 和应急指挥终端等, 支撑模型推理、数据存储、现场感知与指挥交互。

5.2.2 软件基础环境包含操作系统、容器化平台 (Docker/K8s)、数据库管理系统、模型推理框架和通信协议组件等, 保障代理式人工智能稳定运行。

5.3 数据资源层

整合应急管理全量基础数据, 构建标准化数据库, 包括:

- 存储气体、水文、气象、消防和电气等实时监测数据的环境感知数据库;
- 存储设备身份、技术参数、权属位置、检验状态和运行生命周期等信息的特种设备库;
- 存储厂区平面图、地理信息系统 (GIS) 地理图、建筑 BIM 模型、消防设施分布和逃生路径等数据的 2D/3D 图资库;
- 存储物质属性、危险性分类、理化特性、存储运输和应急处置等信息的化学品库;
- 存储物资目录、库存、地理分布、调度方案和供货商信息的应急资材库;
- 存储气体扩散、爆炸冲击、烟雾传播和人员疏散仿真数据的事事故影响范围仿真库;
- 存储避难空间、建筑仿真、疏散节点和动态引导等数据的人员逃生路线数据库;
- 存储综合预案、专项预案、现场处置方案及关键基础数据的应急预案库。

5.4 智能引擎层

应配置代理式人工智能系统级技术支撑模块，编排各专业化功能模块，完成应急管理任务端到端自主处理，包括：

- a) 支持语言、音频、图像、视频多模态输入，完成指令解析、意图识别、意图澄清与多查询扩展（MQE）生成的感知与意图理解模块；
- b) 基于 Plan-and-Solve 范式，实现高层应急目标拆解、多步骤规划、分步执行、状态管控与计划输出的规划模块；
- c) 封装内外工具库，支持环境感知、特种设备查询、预案调取、2D/3D 图资检索、化学品数据查询、事故仿真调取、气象数据获取与指令编排调用的工具调用模块；
- d) 包含工作记忆、情景记忆、语义记忆、感知记忆，支持编码、存储、检索、整合和遗忘全流程管理的记忆管理模块；
- e) 依据规划与感知结果生成处置方案，支持行动选型、任务执行与现场环境交互的行动模块；
- f) 作为系统核心调度中枢，遵循“组合优于继承”原则调度内外组件，转换 OCAA 处置流程生成可执行计划的协调者（Orchestrator）模块；
- g) 完成执行结果评估复盘，接收人机交互反馈并更新约束条件、迭代处置策略的反馈与优化模块；
- h) 实现多模型协议标准化、路由调度、鉴权限流和成本监控的模型接入模块。

5.5 应用层

面向应急管理业务场景，提供核心应用功能，包括：

- a) 完成预案结构化导入、动态生成、查询修改和导出共享，调用文本切割工具提取元数据并依托语义感知生成层级化文档片段的应急预案管理；
- b) 执行事故隔离、禁止进入、危害指认、风险估量、决策制定和方案生成的事故评估应用；
- c) 基于 RECEVOR 流程，实现救援疏散、防暴露、围堵、排险、通风、检修和复原全流程指挥的应急指挥调度应用；
- d) 支持实时调阅事故状况、行动计划、安全考量、人员指派数据的指挥权移转应用；
- e) 支撑演练场景构建、流程仿真、效果评估与预案优化的应急演练应用。

5.6 交互层

适配多终端、多模态人机交互，包括：

- a) 适配 Web、App、语音终端、命令行界面（CLI）和 API 等多端接入，标准化输入格式，实现异步通信与安全鉴权的接入层；
- b) 维护会话上下文、消息路由、会话超时处理，保障多轮交互连贯性的会话层；
- c) 支持文字、语音、图像输入输出，实现语音转文字、文字转语音、图像识别解析的多模态交互模块；
- d) 基于 2D/3D 图资，实现事故位置、影响范围、应急资源和疏散路径可视化呈现的可视化展示模块。

6 功能要求

6.1 基本功能

6.1.1 Markdown 文档处理

- 6.1.1.1 应支持标题、加粗、斜体、删除线、有序/无序列表、引用、代码块、链接、图片和分割线。
- 6.1.1.2 应支持 UTF-8 编码、HTML 混编、实时预览、导出为 HTML/PDF/Markdown 文件。

6.1.2 LLM 调用封装

- 6.1.2.1 应提供标准化接口及统一返回格式，支持多模型智能路由、负载均衡、熔断降级和超时重试。
- 6.1.2.2 应具备调用次数、词元（Token）消耗、时延、失败率统计，支持限流、黑白名单和权限控制。
- 6.1.2.3 应提供提示词模板增删改查、版本管理、分类标签及变量替换。

6.1.3 MCP Server 服务

- 6.1.3.1 应支持文件、数据库、API、传感器数据的标准化暴露及权限管控。
- 6.1.3.2 应提供工具注册、发现、调用、参数校验、异步执行、超时控制和结果缓存。
- 6.1.3.3 应支持结构化提示词模板绑定工具/资源/权限。
- 6.1.3.4 应具备开放身份认证协议（OIDC）认证、角色权限、数据脱敏和调用审计日志能力。

6.1.4 数据查询功能

应支持以下数据查询功能：

- a) 实时/历史气体、温湿度、风速风向、液位、烟雾、火焰和电气参数查询；
- b) 按编号、位置、类型、检验状态、到期预警查询台账及运行记录；
- c) 厂区平面图、楼层布局、消防通道、逃生路径、危险源分布和设备点位查询与图层切换；
- d) 按化学文摘号（CAS）号、名称、联合国编号（UN）号、危险类别查询理化性质、安全技术说明书（SDS）、禁忌配伍、灭火介质、泄漏处置和防护要求；
- e) 按类别、规格、数量、存放地、保质期、责任人查询库存、调拨及领用记录；
- f) 按事故类型、响应级别、部门检索综合预案、专项预案、现场处置方案及附件。

6.1.5 指令解析功能

- 6.1.5.1 应自动修正错别字、同音字、语音转写错误。
- 6.1.5.2 应识别意图并提取时间、地点、对象、动作和条件等关键要素。
- 6.1.5.3 应拆解复杂指令为结构化子任务清单，将口语化表达映射为代理式人工智能标准术语并匹配对应工具接口。

6.1.6 可视化展示

- 6.1.6.1 应支持 2D 地图叠加危险源、设备、传感器、物资、疏散路线和隔离区。
- 6.1.6.2 应支持 3D/BIM 模型分层查看、设备定位、管线查看、风险标注和实时数据叠加。
- 6.1.6.3 应提供应急态势看板，展示事件状态、响应级别、资源分布、人员到位和处置进度。
- 6.1.6.4 应支持现场摄像头联动、多画面查看、云台控制和录像回放。

6.2 拓展功能

6.2.1 应急管理代理式人工智能

- 6.2.1.1 宜采用 Plan-and-Solve 范式，具备任务规划、分步执行和闭环迭代能力。
- 6.2.1.2 宜按 OCAA 逻辑拆解复杂应急任务，输出行动计划并自动校验、回退、重规划。
- 6.2.1.3 集成工作、情景、语义、感知四类记忆，宜支持多轮交互、反馈修正、重要信息持久化、冗余信息清理，适配应急场景动态变化。

6.2.2 AI 应急预案智能管理

- 6.2.2.1 应自动结构化解析预案文档，保留层级关系并提取适用范围、响应分级、组织机构、职责、响应流程、处置步骤、联系方式和物资清单等核心要素。
- 6.2.2.2 可根据事故类型、地点、物质、气象等实时数据，动态匹配基准预案、填充变量、适配流程，生成文本预案、处置清单、指挥指令、任务分派表。
- 6.2.2.3 应支持在线编辑、审核流程、版本回溯、演练优化建议生成。

6.2.3 AI 事故智能评估

AI 事故智能评估应具有以下功能：

- a) 自动采集事故时间、地点、类型、物质、设备、气象和人员分布等信息；
- b) 识别危险源及重大危险源；
- c) 自动划定热区/暖区/冷区、生成隔离边界；
- d) AI 识别 PPE 合规性并预警违规进入；
- e) 图像识别危害源、匹配物质信息；

- f) 评估事实、可能性、现状；
- g) 优先保障人员安全，匹配响应级别并推荐处置策略
- h) 输出结构化行动计划、责任单位、时间节点和资源需求。

6.2.4 智能应急指挥调度

智能应急指挥调度宜具有以下功能：

- a) 自动定位人员、生成搜救优先级及疏散路线、推送广播/短信/大屏指引；
- b) 检测 PPE 穿戴合规性、联动传感器监测环境浓度并预警；
- c) 定位污染源、输出切断指令、推荐围堵方案；
- d) 根据物质类型推荐灭火剂、输出关停设备指令；
- e) 基于气体类型/浓度/风向推荐通风策略、联动通风设备；
- f) 持续监测环境指标、输出隐患排查清单；
- g) 生成洗消方案、恢复计划、复盘改进清单；
- h) 自动生成并推送指挥指令。

6.2.5 任务协同与指挥权移转

任务协同与指挥权移转宜具有以下功能：

- a) 支持应急组织架构（指挥官、工安、联络、操作、后勤、计划和财务）及小组配置、替代顺序、权限分配；
- b) 按职责、距离、能力、负载自动分派任务，生成任务单、时限和验收标准；
- c) 通过短信、App、语音广播、大屏等多渠道推送任务，支持回执、执行反馈；
- d) 实时跟踪任务状态（待接收/执行中/已完成/异常）；
- e) 一键导出指挥数据快照，支持权限临时授权、正式移交、逐级交接，新任指挥官可无缝查看完整上下文与最新状态。

6.2.6 事故仿真与预警

事故仿真与预警宜具有以下功能：

- a) 支持气体扩散、火灾爆炸、人员疏散仿真，输出浓度分布、影响范围、温度场、超压、疏散时间、拥堵点；
- b) 自动生成蓝/黄/橙/红预警，触发对应处置流程与通知范围；
- c) 仿真结果可叠加至 2D/3D 图资，直观展示风险态势。

6.2.7 应急演练支持

应急演练支持宜具有以下功能：

- a) 支持自定义演练场景、事故参数、初始条件、时间线和角色配置；
- b) 按预案/RECEVOR/OCAA 自动生成演练脚本、节点、任务和指令；
- c) 自动记录操作、指令、响应时间、处置动作和资源消耗；
- d) 自动评估响应及时性、处置合规性、协同效率、资源到位率，生成演练报告与改进建议。

7 性能要求

7.1 通用响应性能

- 7.1.1 普通数据查询、页面加载、地图浏览响应时间应不大于 1 s。
- 7.1.2 LLM 文本问答、指令生成响应时间应不大于 5 s。
- 7.1.3 语音转文字、图像识别等多模态交互响应时间应不大于 2 s。
- 7.1.4 复杂推理、预案生成、事故评估应分阶段设置响应指标，输出初步评估结论、简要处置提示响应时间应不大于 3 s，输出完整事故评估报告、完整动态应急预案响应时间应不大于 10 s。

7.2 并发与稳定性

- 7.2.1 应支持不小于 100 用户同时在线，不小于 50 路感知数据并发接入。

7.2.2 应 7×24 h 连续运行，年可用率应不小于 99.9%，单次故障恢复时间应不大于 30 min。

7.2.3 高并发下无卡顿、无崩溃、无数据丢失，关键操作成功率应不小于 99.95%。

7.3 数据处理性能

7.3.1 环境感知数据采集频率应不小于 1 Hz，传输延迟应不大于 2 s，数据丢失率应不大于 0.1%。

7.3.2 海量时序数据应支持秒级查询、快速聚合与趋势统计。

7.3.3 2D/3D 图资加载时间应不大于 3 s，图层切换、模型旋转缩放流畅无卡顿。

7.3.4 化学品、特种设备、预案等结构化数据检索时间应不大于 1 s。

7.4 人员疏散仿真性能

7.4.1 应支持单层、多层及整厂区人员疏散仿真，模型精度应满足应急决策要求。

7.4.2 不超过 500 人场景疏散仿真计算时间应不大于 10 s，不少于 5000 人场景疏散仿真计算时间应不大于 60 s。

7.4.3 可用安全疏散时间 (ASET) 应大于 180 s，输出疏散时间、拥堵点和安全出口利用率等量化指标。

7.5 化学品与特种设备管理性能

7.5.1 重大危险源自动识别、标记、统计响应时间应不大于 2 s。

7.5.2 化学品库存预警、保质期提醒实时触发，延迟应不大于 5 min。

7.5.3 特种设备检验到期应提前 30 d 自动预警，状态更新延迟应不大于 5 min。

7.6 AI 模型推理性能

7.6.1 私有化部署入门级 (7B~14B 参数规模大语言模型) 时，单轮推理平均时延应不大于 5 s，吞吐量应不小于 20 次/分钟；私有化部署企业级 (70B 参数规模大语言模型) 时，单轮推理平均时延应不大于 15 s，吞吐量应不小于 5 次/分钟。

7.6.2 支持模型动态扩容、负载均衡，推理失败自动重试，重试成功率应不小于 99%。

8 接口要求

8.1 通用接口要求

8.1.1 接口通信应采用 HTTP/HTTPS 协议，数据传输格式为 JSON，编码统一为 UTF-8。

8.1.2 接口应具备身份认证、权限校验、参数校验、异常捕获和日志记录能力，保障调用安全可靠。

8.1.3 接口响应应包含统一结构，包括状态码、提示信息、数据体和时间戳。

8.1.4 接口应支持限流、熔断、降级，保障高并发下服务稳定。

8.2 模型服务接口

8.2.1 LLM 基础接口应支持文本生成、问答、摘要、翻译和指令解析，输入包含参数配置、会话 ID 等，输出返回文本结果及调用信息。

8.2.2 多模态接口应支持图像识别、语音转文字、文字转语音，兼容主流格式，响应包含解析结果及置信度。

8.2.3 模型管理接口应支持模型注册、配置更新、状态查询、负载信息获取，便于多模型调度与运维。

8.3 数据资源接口

8.3.1 环境感知数据接口应支持实时数据推送、历史数据查询、测点信息获取，按时间范围、测点 ID、指标类型筛选，批量数据支持分页。

8.3.2 空间图资接口应支持 2D 地图底图加载、图层控制、点位标注、3D 模型加载、视角控制和空间查询，适配 Web 端与大屏展示。

8.3.3 基础台账接口应支持化学品、特种设备、应急资材、应急预案数据的增删改查、批量导入导出和数据同步，字段规范、兼容多系统对接。

8.4 MCP 协议接口

- 8.4.1 遵循 MCP 协议，采用 JSON-RPC2.0 交互，支持 stdio、SSE 两种通信模式。
- 8.4.2 资源接口应支持文件、数据库、传感器数据的标准化暴露，可配置访问权限、数据脱敏规则。
- 8.4.3 工具调用接口应支持工具注册、参数校验、异步执行、结果返回和超时控制，兼容内外工具集成。
- 8.4.4 提示词接口应支持模板管理、变量替换、权限绑定，适配应急场景专用提示词调用。
- 8.4.5 系统接口能力应与 5.1.4 规定通信协议匹配，除 MCP 外，应支持 A2A、ANP 协议接入代理式人工智能，实现不同代理式人工智能之间消息交互、工具调用。

8.5 第三方系统对接接口

- 8.5.1 应支持与企业制造执行系统（MES）、企业资源计划（ERP）、消防监控、视频平台、应急指挥系统对接，提供标准化数据同步接口。
- 8.5.2 视频监控接口应支持实时视频流获取、云台控制、录像回放、告警联动，兼容主流设备协议（如 RTSP/RTMP）。
- 8.5.3 应急指挥接口应支持指令下发、任务回执、状态同步和指挥权交接，保障跨系统应急业务协同。

9 部署环境要求

9.1 私有化大语言模型部署

9.1.1 硬件

硬件配置应符合以下规定：

- a) 入门级（7B~14B 参数规模大语言模型）：CPU 不小于 16 核，内存不小于 64 GB，存储容量不小于 500 GB；
- b) 企业级（70B 参数规模大语言模型）：CPU 不小于 32 核，内存不小于 128 GB，存储容量不小于 1TB。

9.1.2 软件

操作系统宜为 Ubuntu22.04 长期支持(LTS)，配置对应驱动、统一计算设备架构 Toolkit，采用 Docker 容器化部署，推理框架选用 vLLM、Ollama、文本生成推理（TGI）等。

9.2 MCP Server 部署

- 9.2.1 软件环境应支持 Node.js（v18+）、Python（3.10+），采用 npm/pip/uv 包管理工具。
- 9.2.2 本地部署支持 stdio 通信，容器化部署支持 SSE 通信，开放对应端口，配置沙盒权限保障安全。
- 9.2.3 CPU 无特殊要求，内存 100 MB~500 MB，存储按索引数据量适配。

9.3 基础数据库部署

9.3.1 硬件

硬件应符合以下规定：

- a) 关系型数据库为 CPU 不小于 4 核，内存不小于 16 GB，SSD 存储；
- b) 时序数据库为内存不小于 32 GB，大容量存储，支持冷热数据分离。

9.3.2 软件

操作系统选用 Linux，采用 Docker/K8s 容器化部署，文件系统推荐 XFS/ZFS，配置主从复制、双机热备保障高可用。

9.3.3 网络

内网部署，公网不应开放数据库端口，配置内网负载均衡与连接池，保障高并发接入。

10 安全要求

10.1 基本要求

10.1.1 网络安全能力应符合 GB/T 22239—2019 的三级及以上规定，网络数据防护安全应符合 GB/T 44462.4—2026 的规定

10.1.2 个人信息处理安全应符合 GB/T 35273 的规定，敏感个人信息处理安全应符合 GB/T 45574 的规定。

10.1.3 应遵循最小权限、职责分离、安全默认原则，对用户、角色、权限进行精细化管控，杜绝越权访问与操作。

10.1.4 应建立安全管理制度与操作规程，明确安全责任主体，定期开展安全培训、风险评估、漏洞整改与应急演练。

10.2 应用系统

10.2.1 应支持账号密码、短信验证码、令牌和生物识别等多因素认证，关键操作（如指挥指令下发、数据删除）需二次核验。

10.2.2 应按角色分配功能权限、数据权限、接口权限；支持权限动态调整、临时授权、权限回收，操作留痕可追溯。

10.2.3 应防范结构化查询语言（SQL）注入、跨站脚本、越权访问、文件上传、恶意代码和暴力破解及提示词注入等常见攻击，定期进行漏洞扫描、渗透测试并及时修复。

10.2.4 遵循安全编码规范，开展代码审计，第三方组件需安全检测，禁用存在高危漏洞的组件。

10.2.5 应记录用户登录、操作、接口调用、数据访问、模型推理和应急处置等全链路日志，日志包含时间、主体、行为、结果和互联网协议（IP）等要素，留存应不小于6个月，支持查询、导出、审计。

10.3 运行环境

10.3.1 私有化部署应与外网物理或逻辑隔离，仅开放必要内网端口；部署防火墙、入侵检测/防御系统、防病毒网关和堡垒机，限制非法访问与攻击。

10.3.2 操作系统、数据库、中间件、模型推理框架应及时更新补丁，关闭不必要服务、端口与账号，禁用弱口令，开启主机安全防护，防范恶意程序与入侵。

10.3.3 Docker/K8s 容器镜像应进行安全扫描，清理漏洞与敏感信息，配置容器最小权限，限制容器间、容器与主机的访问，定期更新镜像与编排组件。

10.3.4 私有化大模型推理环境应独立部署，与训练环境和管理环境进行网络隔离；模型调用应鉴权、限流、审计；应对模型输入输出内容应进行安全过滤与合规检测，防范生成有害、违规或危险指令。

10.3.5 应急指挥终端、感知终端和摄像头等设备应身份认证、固件加固、加密传输，定期更新固件，防范劫持、篡改、非法接入。

10.4 数据安全

10.4.1 数据分类分级应符合 GB/T 43697 的规定，网络数据处理安全应符合 GB/T 41479 的规定。

10.4.2 数据采集应明确采集范围、用途、期限，不应过度采集个人信息与敏感数据。

10.4.3 敏感/核心数据应采用国密算法加密存储，数据库开启访问控制、审计日志、备份恢复，定期清理冗余和过期数据。

10.4.4 接口、内外网数据传输应采用 HTTPS/TLS 加密，MCP、A2A、ANP 协议通信应加密，防止数据窃取、篡改、劫持。

10.4.5 数据访问应权限审批，敏感数据脱敏后使用，不应未经授权的数据共享、导出、外发，模型推理时脱敏敏感数据，防范数据泄露。

10.4.6 应采用全量备份+增量备份，每日全量、实时增量，备份文件异地存储、加密保护，定期开展恢复演练，确保数据可快速恢复。

10.4.7 过期、废弃数据应进行销毁，不可恢复，敏感数据销毁应审批、记录、审计，防止泄露。

10.5 代理式人工智能行为安全

10.5.1 决策可解释性

代理式人工智能引擎生成的关键决策与指令，应能提供可追溯、可审计的推理过程，至少应包括推理依据、推理步骤和结论生成逻辑。

10.5.2 行为安全护栏

平台应具备对代理式人工智能高风险自主操作的安全护栏机制，至少包括：

- a) 对关停关键生产设备、启动大范围疏散广播、切断能源供应等不可逆操作，应在代理式人工智能输出指令时即触发人工确认界面；
- b) 对超出预设阈值（如疏散范围、资源调配规模）的决策，应自动触发熔断，暂停执行并等待人工介入。

10.5.3 行为审计

应记录代理式人工智能的任务规划、推理过程、工具调用和执行结果等全链路日志，日志留存时间应不小于6个月，并应支持按事件回溯、按时间段回放，便于事后复盘与责任追溯。

10.5.4 事实约束与溯源验证

10.5.4.1 系统应对代理式人工智能生成内容中的关键事实信息进行自动核验，核验范围至少应包括：

- a) 引用的化学品性质、设备参数和预案条款等基础数据，应与数据资源层中的权威来源进行一致性比对，比对结果置信度低于95%时，应在输出栏标注“数据存疑”警示；
- b) 涉及法规标准、安全阈值等约束性信息，核验其准确性与时效性，当引用的标准已被修订或废止时，应能自动显示“标准已更新”，并推送最新有效版本内容；
- c) 发现事实不一致或信息过时，应标注并提示复核。

10.5.4.2 系统应以可视化方式展示决策依据的溯源路径，溯源信息至少应包括：

- a) 决策所引用的具体数据来源（如环境感知数据编号、化学品库条目、应急预案条款编号等）；
- b) 决策推理的关键步骤与逻辑链条。

10.5.4.3 溯源信息应与决策指令同步呈现，便于快速验证决策依据的合理性与准确性。

11 代理式人工智能调试

11.1 功能要求

通过功能测试、场景模拟、案例验证，逐项测试基本功能与拓展功能，验证功能完整性、可用性、准确性。

11.2 性能要求

通过性能测试工具、压力测试、场景仿真，测试响应时间、并发能力、数据处理效率和仿真精度等指标。

11.3 接口要求

通过接口测试、联调测试、兼容性测试，验证协议接口、数据接口、模型接口、终端接口的规范性、互通性和稳定性。

11.4 部署环境要求

通过硬件配置核查、软件环境审查、部署方案审核、现场验证，验证私有化模型、MCP Server、基础数据库部署环境的合规性、适配性。

11.5 安全要求

通过安全测评、漏洞扫描、渗透测试、文档审查、现场核查，验证应用系统、运行环境和数据安全的防护能力。